

XXVI SIMPÓSIO BRASILEIRO DE RECURSOS HIDRÍCOS

PREVISÃO DE VAZÕES NO RIO IGUAÇU E NO RIO AMAZONAS UTILIZANDO MODELO DE REDES NEURAIS

Pérsio Puertas Garcia Lorenti¹; Wagner Przibiciem²; Julio Gomes³ & Daniel Detzel⁴

Abstract: Streamflow prediction models are essential tools for water resources management and planning, as they can be used to forecast extreme events that significantly impact vulnerable regions. Among the options available for short and long-term streamflow prediction are machine learning models, such as the Feedforward Neural Network (FNN). This study aims to evaluate the application of FNN models to the Iguaçu River in União da Vitória and the Amazon River in Óbidos for predicting daily average flows using historical flow data. The developed models differ from each other by varying three key parameters: the number of preceding flows used as inputs (n), with n set to 1, 7, and 30; the forecast horizon (h) in days, where h ranges from 1, 2, 7, and 30 for the Iguaçu river and 1, 7, and 30 for the Amazon river; and adjustments to historical series by subtracting the monthly average flow from the daily average flows. These variations resulted in 42 distinct models, whose performance was evaluated using widely recognized statistical parameters in hydrology. The results showed both that the characteristics of the Amazon River in Óbidos contribute to better model performance, and the increase in the forecast horizon (h) for the Iguaçu River in União da Vitória results in a significant decline in prediction quality.

Resumo: Modelos de previsão de vazões são ferramentas essenciais para a gestão e o planejamento de recursos hídricos, uma vez que podem ser utilizados para prever eventos extremos que impactam significativamente regiões vulneráveis. Entre as opções que podem ser utilizadas para a previsão de vazões de curto e longo prazo estão os modelos de aprendizado de máquina, como a *Feedforward neural network* (FNN). O presente trabalho visa avaliar a utilização de modelos FNN no rio Iguaçu em União da Vitória e no rio Amazonas em Óbidos para a previsão de vazões médias diárias a partir das vazões anteriores. Os modelos desenvolvidos diferem entre si pela variação de três parâmetros básicos: número de vazões anteriores usadas como entrada (n), sendo n igual a 1, 7 e 30; horizonte de previsão (h) em dias, onde o valor de h foi igual a 1, 2, 7 e 30 para o rio Iguaçu e 1, 7 e 30 para o rio Amazonas; e, por fim, a alteração das séries históricas subtraindo a vazão média mensal das vazões médias diárias. Essas variações resultaram em 42 modelos, os quais tiveram seus resultados avaliados pelo cálculo de parâmetros estatísticos amplamente utilizados em hidrologia. Os resultados mostraram que as características do rio Amazonas em Óbidos levam a modelos com melhor desempenho e que o aumento do horizonte de previsão (h) para o rio Iguaçu em União da Vitória implica em uma grande perda na qualidade das previsões.

Palavras-Chave – Previsão de vazões, Rede neural, Eventos extremos.

1) Universidade Federal do Paraná (UFPR), Programa de Pós-Graduação em Engenharia de Recursos Hídricos e Ambiental, Centro Politécnico – bloco V, Jardim das Américas, Rua Francisco H. dos Santos, n.º 100, CEP: 81531-000, Curitiba/PR, +55 (41) 3361-3210, persiopgl@gmail.com

2) Universidade Federal do Paraná (UFPR), Departamento de Hidráulica e Saneamento (DHS), Centro Politécnico – bloco V, Jardim das Américas, Rua Francisco H. dos Santos, n.º 100, CEP: 81531-000, Curitiba/PR, +55 (41) 3361-3142, przibiciem@gmail.com

3) Universidade Federal do Paraná (UFPR), Departamento de Hidráulica e Saneamento (DHS), Centro Politécnico – bloco V, Jardim das Américas, Rua Francisco H. dos Santos, n.º 100, CEP: 81531-000, Curitiba/PR, +55 (41) 3361-3142, jgomes.dhs@ufpr.br

4) Universidade Federal do Paraná (UFPR), Departamento de Hidráulica e Saneamento (DHS), Centro Politécnico – bloco V, Jardim das Américas, Rua Francisco H. dos Santos, n.º 100, CEP: 81531-000, Curitiba/PR, +55 (41) 3361-3142, detzel@ufpr.br

INTRODUÇÃO

As enchentes normalmente causam impactos sociais, econômicos e ambientais significativos e, apesar da implementação de medidas de controle, ainda representam um grande problema ao redor do mundo (Yu *et al.*, 2022). De forma semelhante, épocas de estiagem podem afetar os meios de subsistência e produção, a saúde das populações e os ecossistemas locais, desencadeando diversos outros problemas (Walker *et al.*, 2024).

De forma geral, as cheias estão se tornando mais frequentes e intensas nas regiões brasileiras caracterizadas por condições úmidas e menos comuns e intensas nas regiões mais secas (Bartiko *et al.*, 2019). No entanto, a região amazônica, caracterizada como úmida, passou por um período de severa estiagem em 2023, enquanto a região sul do país sofreu com cheias intensas.

Diante do exposto, é possível compreender a relevância atribuída aos modelos de previsão hidrológica e a sua aplicação. Segundo Yaseen *et al.* (2016), essas ferramentas são de suma importância para o planejamento e a gestão dos recursos hídricos. Uma possível classificação de modelos matemáticos aplicados a previsão de vazões pode ser feita por meio dos conceitos de modelos orientados a dados e modelos baseados em física (Beven, 2012). Modelos orientados a dados, como os de redes neurais, são construídos e/ou otimizados exclusivamente com base em dados, enquanto os baseados em física buscam reproduzir diretamente o processo que está sendo observado.

De acordo com Ibrahim *et al.* (2022), a previsão de vazões também pode ser dividida em outras duas categorias: previsão a curto prazo (horária ou diária) e a longo prazo (semanal, mensal e anual). Enquanto a primeira é utilizada para o controle e desenvolvimento de sistemas de alerta, a segunda visa prover dados relevantes para o planejamento da operação de reservatórios.

O objetivo do presente trabalho é comparar os resultados de modelos de redes neurais utilizando vazões anteriores como entrada para prever vazões futuras em postos hidrométricos nas bacias do rio Amazonas e do rio Iguaçu. Buscou-se avaliar modelos que englobam as duas categorias mencionadas no parágrafo anterior. Com isso, foram realizadas a análise preliminar das características dos locais escolhidos; a calibração dos modelos com diferentes características; e a comparação entre os resultados obtidos e as séries originais, além da comparação entre as duas localidades, por meio do cálculo de parâmetros estatísticos amplamente utilizados na hidrologia estatística.

MATERIAIS E MÉTODOS

Área de estudo e conjunto de dados

As estações fluviométricas escolhidas para o desenvolvimento do estudo foram União da Vitória (65310000) no rio Iguaçu e Óbidos (17050001) no rio Amazonas. A Figura 1 apresenta a localização das estações fluviométricas, magnitudes e áreas urbanas das duas bacias. É possível verificar, a partir da Figura 1, que as estações possuem características bastante distintas em relação a posição geográfica, área da bacia, magnitude das vazões, tempo de resposta, clima e sazonalidade.

Algumas características de interesse das bacias hidrográficas são apresentadas na Tabela 1. É importante destacar, conforme visto na tabela, os valores de correlação para os *lags* de 7 e 30 dias, os quais sofrem forte influência das dimensões das duas bacias. Adicionalmente, verifica-se, a partir dos valores de correlação, a sazonalidade no rio Amazonas que não é observada no rio Iguaçu.

A escolha da estação fluviométrica União da Vitória (65310000) no rio Iguaçu tem como base o histórico de enchentes e o risco que elas representam para a população do município de União da

Vitória - PR. Além disso, a série histórica conta com dados que propiciam um estudo mais preciso, já que teve início em 1930 e vai até 2017 com falhas apenas no ano inicial de operação.

A estação fluviométrica Óbidos (17050001) no rio Amazonas foi escolhida pois seus dados são uma boa representação desse rio, que possui a maior vazão e a segunda maior extensão do planeta, uma vez que está próxima de sua foz no Oceano Atlântico e possui registros de vazões com dados sem falhas no período de 1970 até 2022.

Figura 1 – Localização das bacias hidrográficas

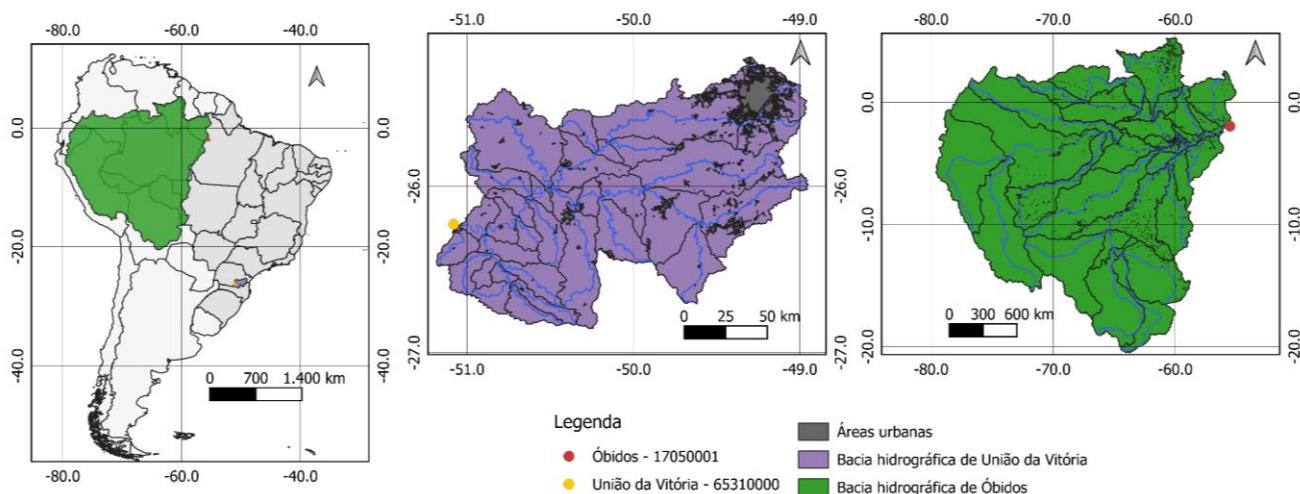


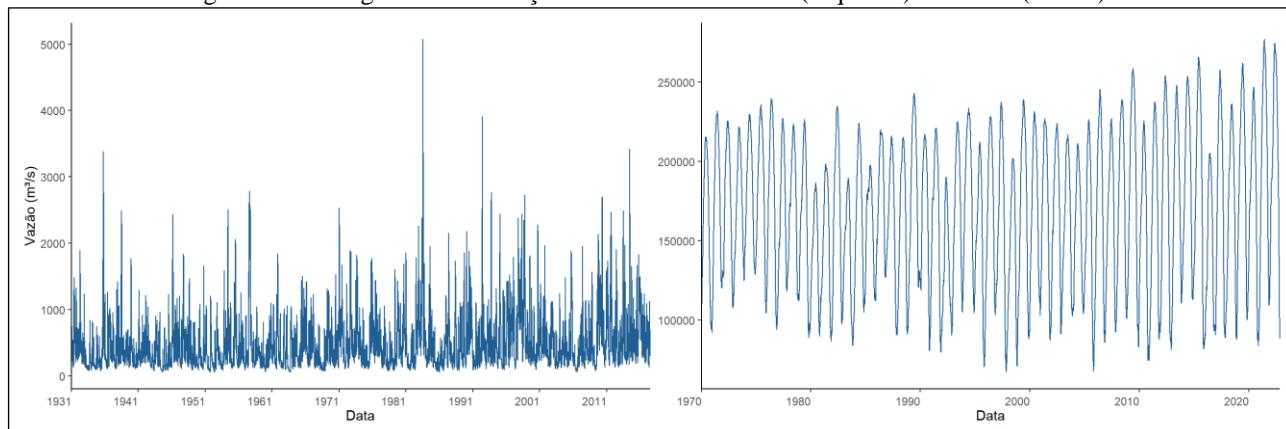
Tabela 1 – Informações básicas sobre as bacias hidrográficas

Estação	União da Vitória	Óbidos
Área de drenagem (km ²)	24.200	4.670.000
Vazão mínima e máxima (m ³ /s)	54 / 5.072	67.038 / 276.916
Vazão média de longo termo (m ³ /s)	495	170.158
Vazão específica média de longo termo (L/s/km ²)	20,3	36,5
Vazão Q ₅₀ (m ³ /s)	346	175.594
Assimetria e coeficiente de variação das vazões	2,48 / 89,9%	-0,13 / 28,4%
Autocorrelação com lag de 1, 7, 30, 180 e 365 dias	0,99 / 0,82 / 0,33 / 0,03 / 0,11	0,99 / 0,99 / 0,86 / -0,77 / 0,86
Autocorrelação parcial com lag de 1, 7, 30, 180 e 365 dias	0,99 / -0,02 / 0,00 / 0,01 / 0,01	0,99 / -0,08 / -0,04 / 0,01 / -0,01
Clima (Köppen)	Temperado, sem estação seca e verão fresco (Cfb)	Tropical Equatorial (Af) Tropical de monção (Am)

A Figura 2 mostra os hidrogramas das séries históricas de União da Vitória e Óbidos, respectivamente, onde é possível destacar os picos acentuados com uma resposta rápida da bacia a

chuvas intensas em União da Vitória e a forte sazonalidade presente em Óbidos. Nesse sentido, registros recentes de eventos hidrológicos extremos em União da Vitória e áreas a montante da estação de Óbidos mostram enchentes e estiagens que causaram fortes impactos.

Figura 2 – Hidrogramas das estações de União da Vitória (esquerda) e Óbidos (direita).



De acordo com as séries disponibilizados pela Agência Nacional de Águas e Saneamento Básico (ANA), em União da Vitória, destaca-se a enchente de 1983, com nível de 10,42 m e cerca de 70% da cidade alagada, seguida por eventos em 1992 (8,89 m), 2014 (8,15 m e aproximadamente 40% da cidade alagada) e 2023 (8,28 m) (Sartori *et al.*, 2023). Em contraste, a estiagem de 2020 registrou o nível mais baixo da série, com 1,29 m. Em relação a Óbidos, as enchentes mais expressivas ocorreram em 2009 (8,39 m), 2022 (8,28 m) e 2021 (8,24 m), enquanto as estiagens de 2023 (-0,92 m) e 2024 (-1,28 m) marcaram os menores níveis registrados.

Modelo para previsão

As redes neurais são modelos específicos de aprendizado de máquina inspirados na estrutura e no funcionamento do cérebro, visando simular a forma como ele processa informação (Poonia *et al.*, 2018). A configuração *Feedforward neural network* (FNN) é formada por unidades básicas chamadas de neurônios ou nós, que são organizadas em camadas e estabelecem uma rede em sentido único (Russel e Norvig, 2020). Cada neurônio coleta informações de outros neurônios anteriores a ele ou, caso esteja posicionado na primeira camada, dos dados de entrada.

Toda conexão na rede conta com um peso – valores altos reforçam a informação recebida e baixos as atenuam (Lewis-Beck *et al.*, 2004). Além dos pesos, há também um componente chamado *bias*, que acompanha cada neurônio e representa uma constante que fornece mais flexibilidade e permite a rede aprender padrões, mesmo quando os valores recebidos são zero.

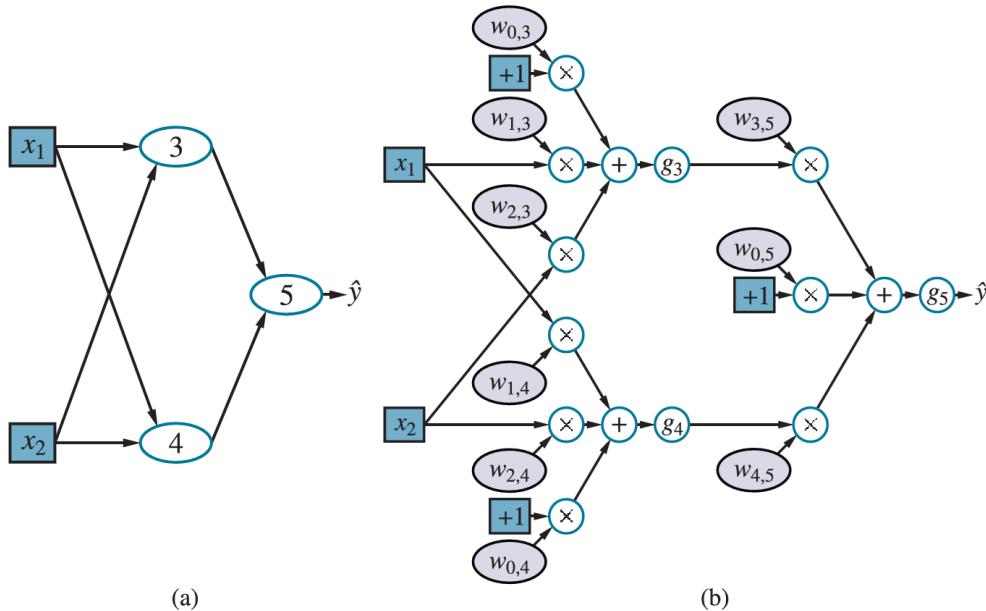
Cada neurônio multiplica os valores que recebe pelo peso correspondente e soma os seus resultados, além de também somar o *bias* associado àquele neurônio. Após isso, antes de enviar o resultado para a próxima camada, ele passa por uma função de ativação (Russel e Norvig, 2020). Essa função transforma a soma ponderada em uma saída não linear, o que ajuda o modelo a aprender padrões complexos.

O item (a) da Figura 3 exemplifica uma FNN com dois parâmetros de entrada (x_1 e x_2), uma camada oculta com dois neurônios (3 e 4) e uma camada de saída com um neurônio (5). Por sua vez, o item (b) da Figura 3 mostra as operações que acontecem na rede, onde $W_{i,j}$ são os pesos, $W_{0,j}$ representa o *bias* e $g(j)$ as funções de ativação.

Os modelos foram construídos com uma camada de entrada, duas camadas intermediárias (com 128 e 64 neurônios) e uma camada de saída. Ademais, para ambas as estações fluviométricas, as

séries históricas foram divididas em 70% para treino e 30% para teste. Para a construção e posterior análise do comportamento dos modelos, três características foram alternadas: o número de vazões anteriores usadas (n), o horizonte de previsão (h) e uma modificação nas séries temporais.

Figura 3 – Representação de uma FNN



O número de vazões anteriores usadas (n) foi analisado para observar até qual distância temporal os modelos conseguiram obter informações relevantes para sua saída e, para isso, os testes foram feitos com n igual 1, 7 e 30 vazões, representando escalas diária, semanal e mensal. Quanto ao horizonte de previsão (h), foram feitos testes com 1, 2, 7 e 30 dias para União da Vitória e com 1, 7 e 30 dias para Óbidos para avaliar a relação entre as dimensões da bacia e o horizonte de previsão em termos de qualidade dos resultados. Não se utilizou um horizonte de previsão (h) de 2 dias para Óbidos porque as correlações de *lags* 1 e 2 se mostraram muito próximas entre si. Por fim, a modificação feita nas séries temporais ocorreu em se utilizar a diferença entre a vazão média diária e a sua respectiva vazão média mensal, buscando eliminar efeitos sazonais e priorizar eventos anômalos.

Considerando os valores de n e h adotados e duas séries de vazões para cada estação fluviométrica (série original e série modificada), foram estabelecidos 24 modelos para União da Vitória e 18 modelos para Óbidos, totalizando 42 modelos distintos.

Com relação à calibração do modelo, diversos algoritmos podem ser escolhidos para esse fim, assim como a função de perda adotada para medir o desempenho do modelo na calibração. O algoritmo utilizado nesse trabalho é chamado de Adam (*Adaptive Moment Estimation*) e a função de perda foi o erro quadrático médio (MSE). O referido algoritmo usa o gradiente da função de perda (derivada da função de perda em relação ao peso) que é obtido por meio das relações entre a função de perda e o valor de saída e entre o valor de saída e o peso, para calcular os momentos de primeira e segunda ordem que são usados na atualização desse peso de forma individual (Reyad e Sarhan, 2023). Enquanto o momento de primeira ordem acumula a direção média dos gradientes, que é usado para que o peso seja atualizado na direção oposta, o de segunda ordem mede sua variância.

Métricas para a avaliação

As métricas estatísticas utilizadas para avaliar o resultado dos modelos foram: raiz do erro quadrático médio (RMSE); coeficiente de Nash-Sutcliffe (NSE); coeficiente de eficiência de Kling-Gupta (KGE); e a tendência percentual (Pbias) (Gupta *et al.*, 2009).

Resumidamente, a RMSE se baseia na diferença entre os valores previstos por um modelo e os valores observados. Por sua vez, o NSE é semelhante à métrica anterior, mas também leva em consideração a média dos dados observados, permitindo a comparação entre resultados de variáveis com magnitudes diferentes. Ainda, o KGE visa uma quantidade maior de informações: a correlação entre as vazões observadas e as previstas, a média das vazões observadas e das previstas e o desvio padrão das vazões observadas e das previstas. Por fim, a Pbias expressa a diferença percentual entre a média dos valores previstos e a média dos valores observados.

RESULTADOS E DISCUSSÕES

As figuras a seguir apresentam o desempenho dos modelos desenvolvidos para as estações fluviométricas União da Vitória (6531000) no rio Iguaçu e Óbidos (17050001) no rio Amazonas, a partir do RMSE (Figura 4), NSE (Figura 5), KGE (Figura 6) e Pbias (Figura 7).

Em relação ao número de vazões anteriores usadas (n), verificou-se, para União da Vitória, que o melhor desempenho para horizonte de previsão (h) igual a 1 dia foi com $n = 30$. Para horizonte de previsão (h) igual a 2 dias e 7 dias, o melhor desempenho foi com $n = 7$. Já para horizonte de previsão (h) igual a 30 dias o melhor desempenho foi com $n = 1$, ou seja, o aumento de h resultou em diminuição de n em termos de desempenho dos modelos. No entanto, destaca-se que os modelos para União da Vitória para h igual a 7 dias e 30 dias não mostraram bom desempenho. Em Óbidos, o melhor desempenho para horizonte de previsão (h) igual a 1 dia foi com $n = 7$. Enquanto para horizonte de previsão (h) igual a 7 dias e 30 dias, o melhor desempenho foi com $n = 30$, ou seja, o aumento de h resultou em aumento de n .

Em relação ao horizonte de previsão (h), como era de se esperar, maiores valores de h resultaram em modelos com pior desempenho. No entanto, destaca-se que foram observados modelos com valores de NSE e KGE superiores a 0,9 para h igual a 1 dia e 2 dias em União da Vitória e para h igual a 1 dia, 7 dias e 30 dias em Óbidos, mostrando o efeito das dimensões das bacias sobre a previsibilidade das vazões.

Em relação à modificação da série de vazões original, para União da Vitória, houve melhoria de desempenho com a modificação da série apenas para os modelos de horizonte de previsão (h) de 30 dias. No entanto, destaca-se novamente que os modelos para União da Vitória para h igual a 7 dias e 30 dias não mostraram bom desempenho. Já para Óbidos, também se observou melhoria no desempenho para horizonte de previsão (h) de 30 dias, mas somente para número de vazões anteriores usadas (n) igual a 1 e 7. Ressaltando-se que, para a referida estação e para $h = 30$, o melhor desempenho foi obtido pelo modelo com série original e $n = 30$.

Como exemplo dos resultados, para os modelos de previsão de curto prazo ($h = 1$ dia) e série original, em União da Vitória, a razão entre RMSE e a vazão média de longo termo variou entre 9,9% e 13,2%; NSE variou entre 0,9821 e 0,9901; KGE, entre 0,9714 e 0,9889; e Pbias, entre -0,6% e 1,9%. Em Óbidos, a variação dos indicadores de desempenho foi: razão entre RMSE e vazão média de longo termo entre 0,4% e 1,7%; NSE, entre 0,9996 e 0,9999; KGE, entre 0,9984 e 0,9999; e Pbias, entre -0,06% e 0,06%.

Figura 4 – Raiz do erro quadrático médio (RMSE)

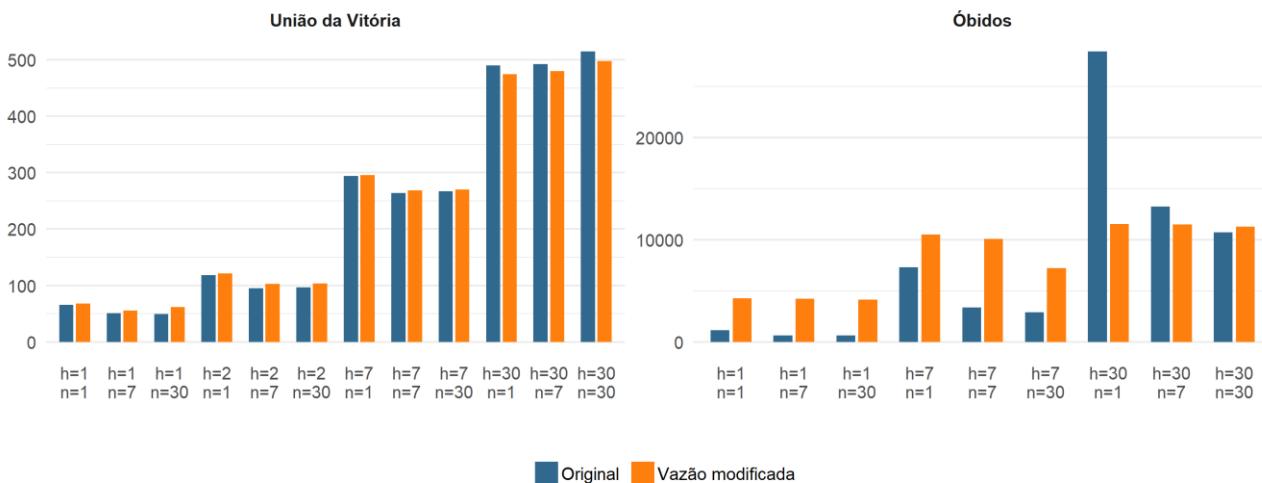


Figura 5 – Coeficiente de Nash-Sutcliffe (NSE)

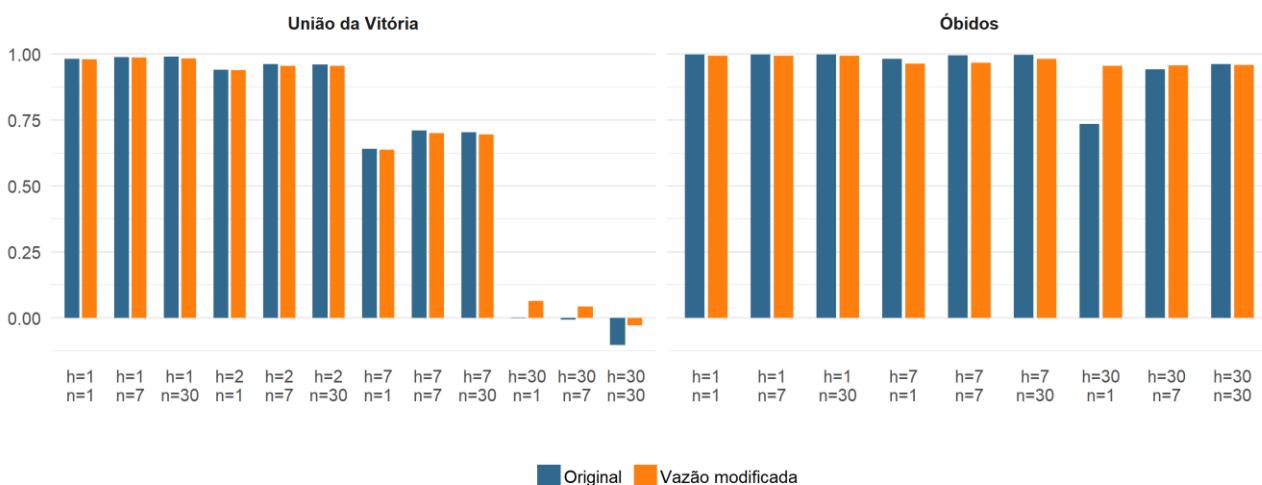


Figura 6 – Coeficiente de eficiência de Kling-Gupta (KGE)

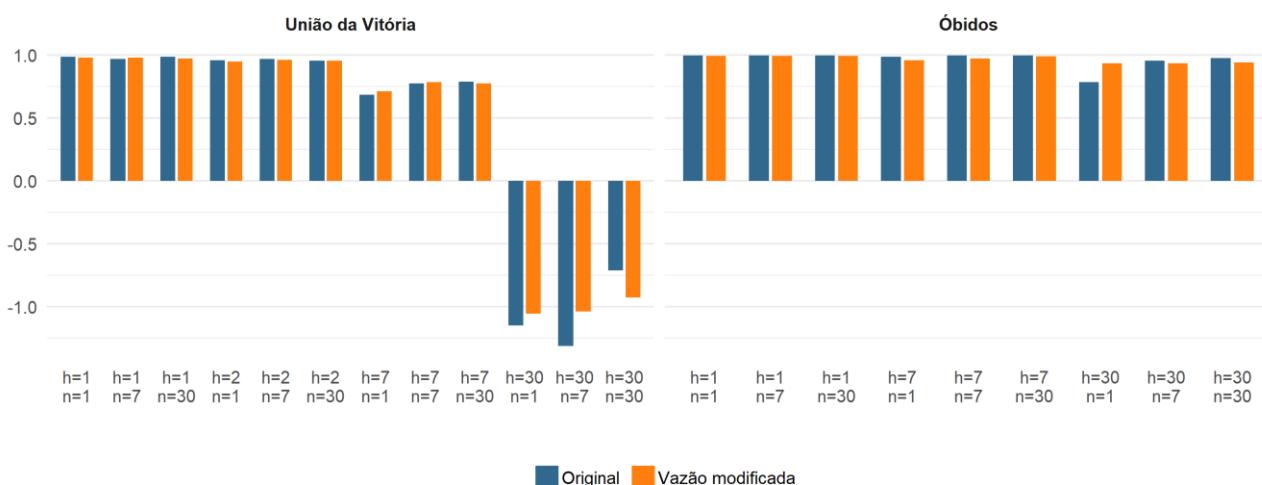
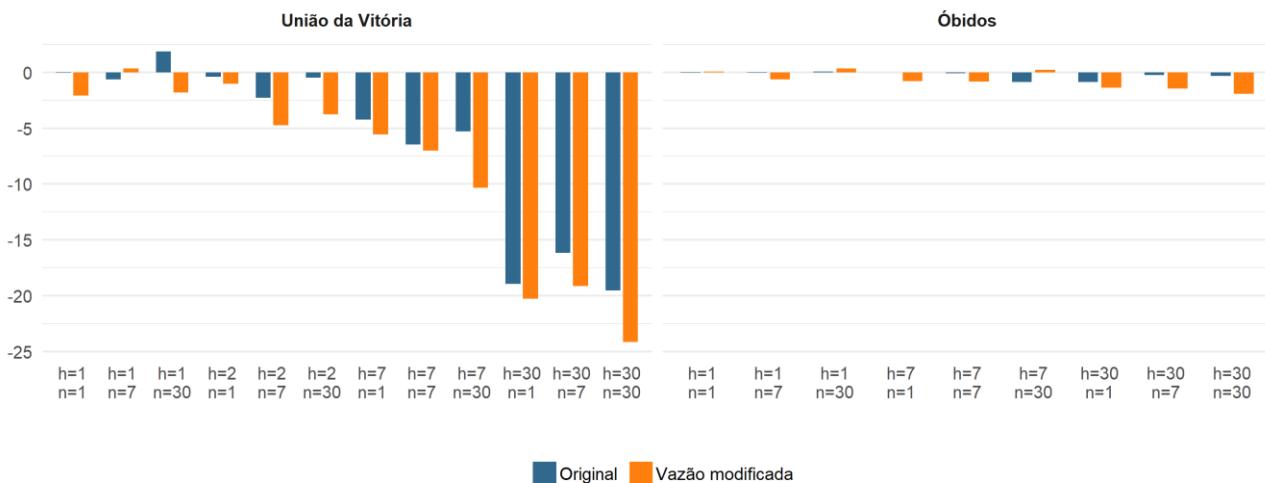


Figura 7 – Tendência percentual (Pbias)



Modelos de previsão com $h = 2$ dias foram desenvolvidos somente para União da Vitória, onde, com a série original, observou-se que a razão entre RMSE e a vazão média de longo termo variou entre 19,2% e 23,9%; NSE, entre 0,9416 e 0,9624; KGE, entre 0,9559 e 0,9712; e Pbias, entre -2,3% e -0,5.

Para os modelos de previsão semanal ($h = 7$ dias) e série original, em União da Vitória, a razão entre RMSE e a vazão média de longo termo variou entre 53,3% e 59,4%; NSE, entre 0,6403 e 0,7105; KGE, entre 0,6856 e 0,7883; e Pbias, entre -6,5% e -4,2%. Em Óbidos, a variação dos indicadores de desempenho foi: razão entre RMSE e vazão média de longo entre 1,7% e 4,3%; NSE, entre 0,9827 e 0,9973; KGE, entre 0,9876 e 0,9980; e Pbias, entre -0,9% e 0,0%.

Por fim, para os modelos de previsão de longo prazo ($h = 30$ dias) e série original, em União da Vitória, a razão entre RMSE e a vazão média de longo termo variou entre 99,1% e 104,1%; NSE, entre -0,1027 e 0,0010; KGE, entre -1,3122 e -0,7123; e Pbias, entre -19,5% e -16,2%. Em Óbidos, a variação dos indicadores de desempenho foi: razão entre RMSE e vazão média de longo entre 6,3% e 16,7%; NSE entre 0,7360 e 0,9624; KGE entre 0,7870 e 0,9624; e Pbias variou entre -0,9% e -0,3%.

De forma resumida, os resultados obtidos mostraram que os modelos para horizonte de previsão (h) iguais a até dois dias apresentaram bom desempenho para União da Vitória. No entanto, a qualidade dos resultados diminui significativamente para h igual a 7 e são muito ruins para h igual a 30. Em Óbidos, foi possível obter modelos com bom desempenho mesmo para h igual a 30. De certa forma, esse cenário já era esperado, uma vez que os eventos de cheia se desenvolvem na ordem de dias em União da Vitória, no rio Iguaçu, e na ordem de meses em Óbidos, no rio Amazonas, em função das dimensões das bacias, conforme os valores de correlação entre vazões para diferentes *lags* apresentados na Tabela 1. Outro fator que colabora para esse comportamento é o clima, onde se observa uma sazonalidade bem caracterizada em Óbidos, o que não se verifica em União da Vitória.

CONCLUSÕES E RECOMENDAÇÕES

Os hidrogramas de cheia em União da Vitória, localizada no rio Iguaçu, comportam-se de forma que as vazões máximas ocorrem relativamente rápido quando comparados aos hidrogramas observados em Óbidos, apresentando variações temporais mais acentuadas, conforme sugere o tamanho da bacia, além do coeficiente de variação e da assimetria calculados a partir da série de vazões.

Por outro lado, Óbidos apresenta transições suaves entre valores de vazões baixas e vazões altas, demonstrando a persistência e a sazonalidade presentes na série. Essas características indicam que, para um modelo que possui como variável independente as próprias vazões observadas, as previsões seriam melhores para Óbidos. Os resultados obtidos com os parâmetros utilizados para avaliar os modelos FNN confirmaram o melhor desempenho dos modelos desenvolvidos para essa estação.

Registrhou-se, além disso, que quase todos os modelos de União da Vitória com horizonte de até 7 dias tiveram desempenho superior ao utilizar 7 vazões anteriores ao invés de um único valor de vazão. Nesse sentido, a série dessa estação possui uma baixa autocorrelação para as distâncias temporais maiores do que sete dias e uma autocorrelação parcial igual a 0 para a distância de trinta dias, o que evidencia uma relação entre esses parâmetros e a quantidade de vazões utilizadas como variáveis independentes. Enquanto isso, o aumento do número de vazões passadas produziu uma melhoria na qualidade de previsão em Óbidos, mas levou a uma diferença significativamente maior na comparação entre os modelos de 1 vazão antecedente para 7 vazões antecedentes do que nos modelos de 7 vazões antecedentes para 30 vazões antecedentes. Ainda, o aumento no horizonte de previsão resulta em uma piora nos desempenhos para as duas estações, apesar de ser algo mais acentuado em União da Vitória.

Com relação ao horizonte de previsão, foi possível notar que maiores valores impactam fortemente os resultados de RMSE, NSE e KGE. Além disso, o comportamento do Pbias tende a resultar em valores cada vez mais negativos, o que indica a dificuldade em prever períodos de cheias com grande antecedência e remete a forte relação que esses eventos possuem com a precipitação.

Ainda, a ideia inicial de subtrair a vazão média mensal para diminuir o efeito da sazonalidade e destacar outras variações se mostrou útil no cenário de longo prazo para Óbidos, uma vez que os modelos com horizonte de previsão de 30 dias e 1 vazão de entrada e de 30 dias com 7 vazões de entrada tiveram um melhor desempenho quando comparados com os modelos sem a modificação na série.

Como recomendação para futuros trabalhos, pode ser considerada a utilização de novas variáveis com o objetivo de aumentar a precisão das previsões nas duas estações estudadas, especialmente para vazões próximas a pontos de mínimas e máximas. Além disso, a implementação de novos modelos pode ajudar a identificar possíveis problemas e servir como comparação para determinar a qualidade dos resultados obtidos.

REFERÊNCIAS

- BARTIKO, D.; OLIVEIRA, D. Y.; BONUMÁ, N. B.; CHAFFE, P. L. B. (2019). “*Spatial and seasonal patterns of flood change across Brazil*”. *Hydrological Sciences Journal*, v. 64, p. 1071–1079.
- BEVEN, K. J. (2012). *Rainfall-runoff modelling: the primer*. 2 ed. Wiley-Blackwell, 488 p.
- GUPTA, H. V.; KLING, H.; YILMAZ, K.; MARTINEZ, G. F. (2009). “*Decomposition of the mean squared error and NSE performance criteria: implications for improving hydrological modelling*”. *Journal of Hydrology (Amsterdam)*, 377(1-2), 80-91.
- IBRAHIM, K. S. M. H.; HUANG, Y. F.; AHMED, A. N.; KOO, C. H.; EL-SHAFIE, A. (2022). “*A review of the hybrid artificial intelligence and optimization modelling of hydrological streamflow forecasting*”. *Alexandria Engineering Journal*, v. 61, p. 279-303.

- LEWIS-BECK, M. S.; BRYMAN, A.; LIAO, T. F. (2004). *The SAGE encyclopedia of social science research methods*. SAGE Publications, 1305 p.
- POONIA, V.; TIWARI, H. L.; MISHRA, S. (2018) “*Hydrological analysis by artificial neural network: a review*”. International Journal of Advance Research, Ideas and Innovations in Technology (IJARIIT), v. 4, n. 3, pp. 265-270.
- REYAD M.; SARHAN, A. M.; ARAFA M. (2023). “*A modified Adam algorithm for deep neural network optimization*”. Neural Computing and Applications, v. 35, p. 17095-17112.
- RUSSEL, S.; NORVIG., P. (2020). “*Artificial intelligence: a modern approach*”. 4 ed. Pearson, 1136 p.
- SARTORI, M.; ZIMMERMAN, A.; UKACHENSKI, S. “*Quatro enchentes em quarenta anos: entenda porque o Rio Iguaçu alaga tanto União da Vitória*”. Disponível em: <https://g1.globo.com/pr/campos-gerais-sul/noticia/2023/10/18/quatro-enchentes-em-quarenta-anos-entenda-porque-o-rio-iguacu-alaga-tanto-uniao-da-vitoria.ghtml>.
- WALKER, D. W.; VERGOPOLAN, N.; CAVALCANTE, L., SMITH, K. H.; AGOUNGBOME, S. M. D.; ALMAGRO, A.; APURV, T.; DAHAL, N. M.; HOFFMANN, D.; SINGH, V.; XIANG, Z. (2024). “*Flash drought typologies and societal impacts: a worldwide review of occurrence, nomenclature, and experiences of local populations*”. Weather, Climate, and Society, v. 16, p. 3-28.
- YASEEN, Z. M.; JAAFAR, O.; DEO, R. C.; KISI, O.; ADAMOWSKI J.; QUILTY J.; EL-SHAFIE A. (2016). “*Stream-flow forecasting using extreme learning machines: a case study in a semi-arid region in Iraq*”. Journal of Hydrology, v. 542, p. 603–614.
- YU, Q.; WANG, Y.; LI, N. (2022). “*Extreme flood disasters: comprehensive impact and assessment*”. Water, v. 14, p. 1211.